AGRUPAMENTO: BANK CUSTOMER SEGMENTATION

<u>Dataset</u>

Códigos

Vitor Lopes Fabris, 769822 Jayme Sakae dos Reis Furuyama, 761044

Sumário

Escolha do conjunto de dados

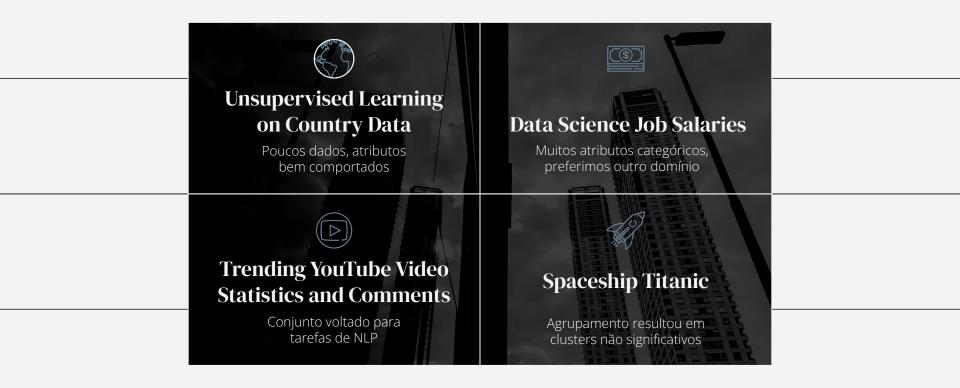
02
Estudo do conjunto de dados

03
Algoritmos de agrupamento

04
Interpretação dos resultados obtidos

Escolha do conjunto de dados

Escolha do conjunto de dados



Bank Customer segmentation

Atributos

- TransactionID
- CustomerID
- CustomerDOB
- CustGender
- CustLocation
- CustAccountBalance
- TransactionDate
- TransactionTime
- TransactionAmount

Alguns dos problemas no Dataset

- Valores Nulos
- Datas Inválidas



MAS ANTES...

Atributos Tratados:

- CustomerDOB
- TransactionDate
- TransactionTime
- CustLocation

Atributos Não Modificados:

- CustAccountBalance
- TransactionAmount
- CustGender

Atributos descartados:

- CustomerID
- TransactionID

MAS ANTES...

TransactionDate e TransactionTime:

Estes dois atributos foram combinados de forma que se transformasse em um único atributo TimeStamp

Formato TransactionDate DD/MM/YY

Formato TransactionTime HourMinSec

Formato TimeStamp Quantidade de segundos a partir do dia 01/01/1970 até a transação

MAS ANTES...

CustLocation

Esse atributo levanta um problema, existem 9275 cidades diferentes, assim para uma melhor visualização e não cair na maldição das dimensões

Consideramos apenas as 3 cidades com maiores transações:

- Mumbai
- Bangalore
- New Delhi

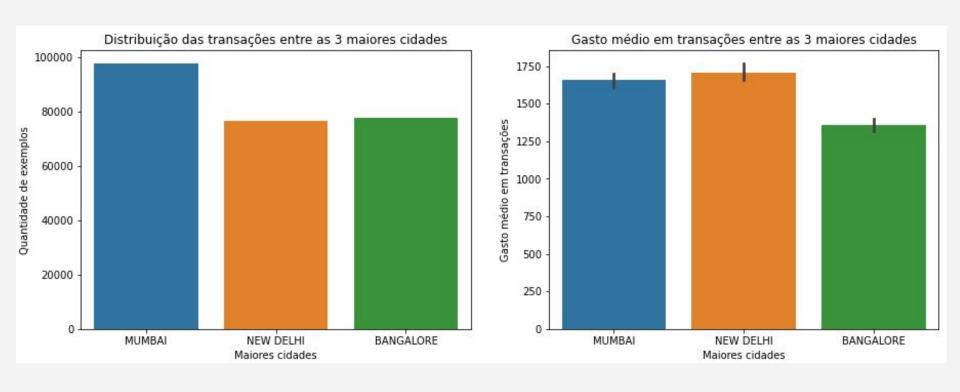
CustomerDOB

Utilizamos apenas o ano de nascimento do cliente

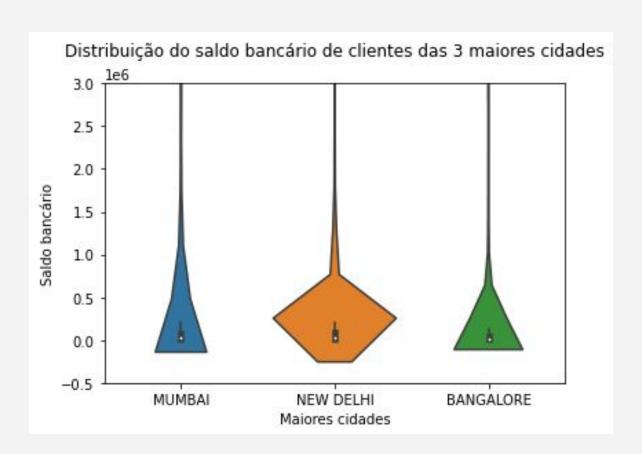
Pessoas que nasceram antes de 1900 foram descartadas



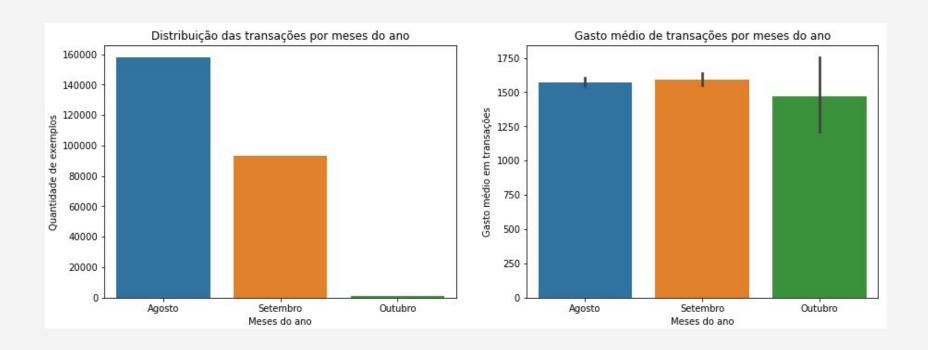
Observando as cidades



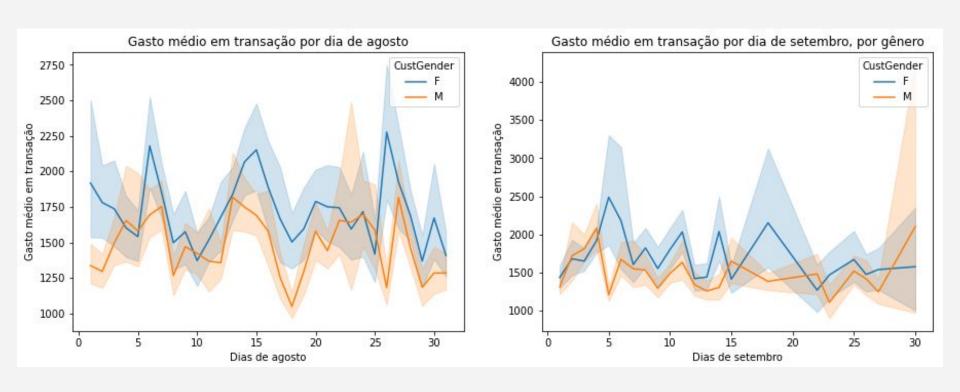
Observando as cidades



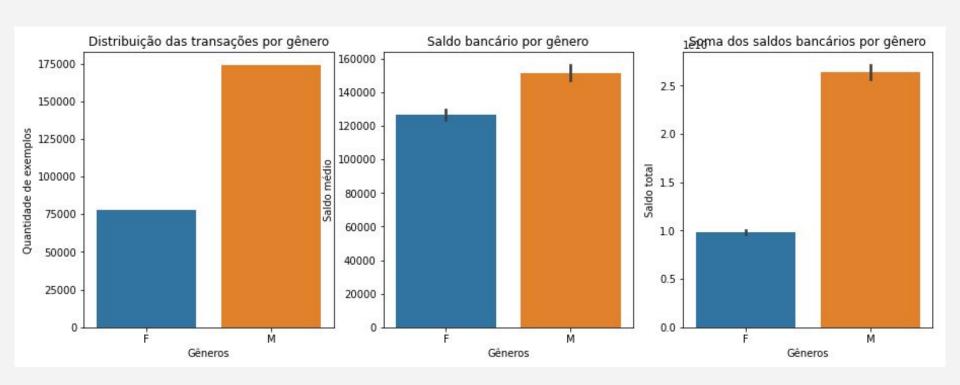
Observando o comportamento no ano



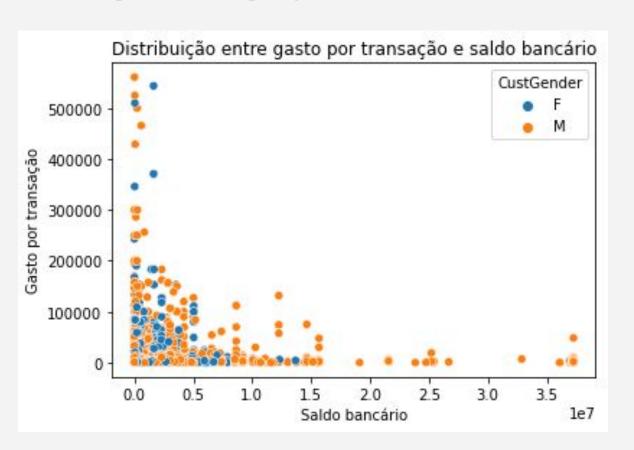
Observando o comportamento no ano



Observando o comportamento por gênero



Observando o comportamento por gênero



Agrupadores Avaliações



Quais avaliadores foram usados?

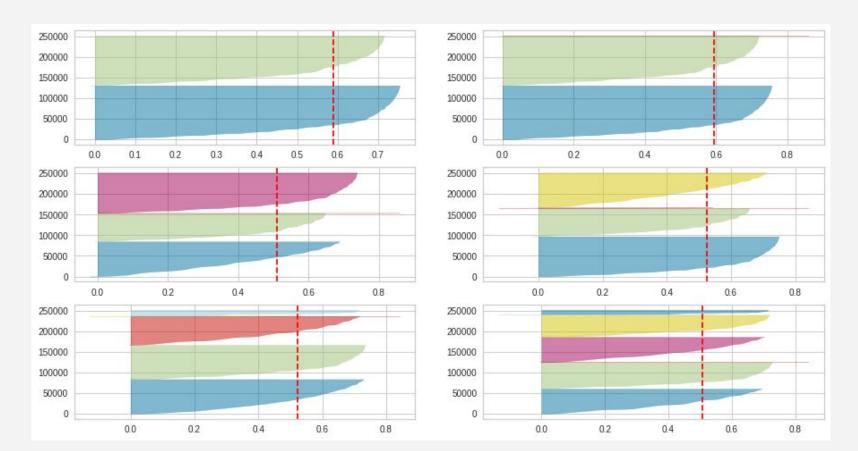
Usamos para o K-Means dois métodos de avaliação, sendo eles:

- Método do cotovelo (ou joelho);
- Silhouette Score

Método do cotovelo no K-Means



Silhouette Score no K-Means





Como o HDBSCAN tem um próprio avaliador, não fizemos uma comparação de avaliação.

Os resultados dos clusters do HDBSCAN com os parâmetros de alfa = 1 e o tamanho mínimo dos clusters de 600, retornou:

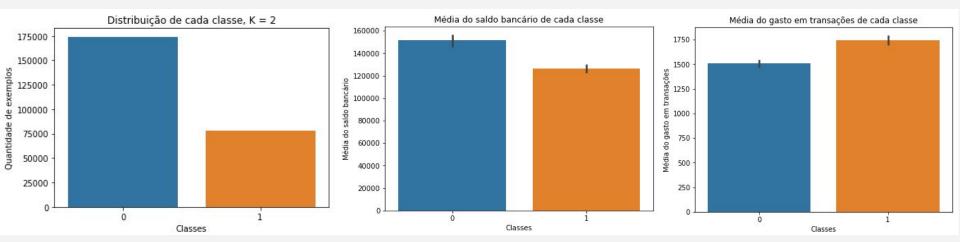
Índice do HDBSCAN	Quantidade de dados
-1	25.341
0	77.692
1	4.956
2	1.016
3	142.805







K = 2



K = 2

